# Transformación y enriquecimiento de datos del proyecto integrador: preparación del dataset de iris para responder las preguntas de negocio

Jesus Gonzalez

Ingeniería de Software y Datos

IU Digital

Proyecto Integrado III - Analítica de Datos (PREICA2602B020038)

Andrés Felipe Callejas

Noviembre de 2026

## Contenido

Transformación y enriquecimiento de datos del proyecto integrador: preparación del dataset de iris para responder las preguntas de negocio ..... 3
1. Introducción ..... 3
2. Necesidad y preguntas de negocio ..... 4
3. Metodología ..... 5
3.1 Transformaciones aplicadas ..... 5
3.2 Reglas de calidad y decisiones sobre los hallazgos ..... 6
3.3 Enriquecimiento de la información ..... 7
3.4 Procedimiento para responder las preguntas ..... 7
4. Diccionario de datos ..... 9
5. Resultados y discusión ..... 9
5.1 Perfil morfológico por especie (P1) ..... 10
5.2 Variación dentro de las especies y distancia entre ellas (P2) ..... 11
5.3 Relación entre sépalo y pétalo (P3) ..... 12
5.4 Distribución por categorías de tamaño (P4) ..... 13
6. Conclusiones del avance ..... 13
7. Referencias ..... 15
Apéndice A. Contenido del resumen descriptivo ..... 16

## Lista de tablas

Tabla 1. Preguntas de negocio, variables necesarias y resultado esperado ..... 4

Tabla 2. Transformaciones aplicadas al dataset y registros afectados ..... 5

Tabla 3. Variables incorporadas en el enriquecimiento ..... 7

Tabla 4. Diccionario de datos del dataset preparado ..... 9

Tabla 5. Media de cada medida por especie, en centímetros ..... 10

Tabla 6. Coeficiente de variación por especie y distancia entre medias, por medida ..... 11

Tabla 7. Correlación de Pearson de cada par sépalo–pétalo, global y por especie ..... 12

Tabla 8. Distribución de especies por categoría de tamaño de flor ..... 13

# Transformación y enriquecimiento de datos del proyecto integrador: preparación del dataset de iris para responder las preguntas de negocio

Transformación y enriquecimiento de datos del proyecto integrador: preparación del dataset de iris para responder las preguntas de negocio

## 1. Introducción

Este documento registra el avance del proyecto integrador en su etapa de transformación y enriquecimiento de datos. La entrega anterior dejó listas las bases del trabajo: el dataset *Iris* publicado en Hugging Face (scikit-learn, 2024) se carga mediante una clase propia que hace la conexión con el Hub, y una segunda clase genera el resumen descriptivo de cualquier *DataFrame* en un archivo de texto. Ese trabajo se concentró en la infraestructura de carga y todavía no definía con qué preguntas de negocio iba a responder el análisis, así que esta etapa empezó por formularlas y dejarlas por escrito.

El ajuste de alcance es deliberado y se documenta aquí: la necesidad de análisis existía desde el planteamiento del proyecto, pero las preguntas se formalizan en esta entrega. Prefiero definirlas ahora, con el dataset ya conocido y validado, antes que forzar preguntas genéricas que luego habría que corregir. Con las preguntas claras, el cuaderno de la entrega aplica las transformaciones que el estado de los datos pedía, incorpora cuatro variables calculadas y produce las tablas que responden cada pregunta (Wickham, 2014). El dataset resulta adecuado para este propósito porque es público, pequeño y completo, y porque sus medidas provienen de las recolecciones clásicas de Anderson en la península de Gaspé, empleadas después por Fisher (1936) en su trabajo sobre medidas múltiples.

El documento se organiza en seis apartados más las referencias. La sección 2 presenta la necesidad y las preguntas. La sección 3 describe la metodología de transformación, las reglas de

calidad y el enriquecimiento. La sección 4 actualiza el diccionario de datos. La sección 5 muestra los resultados y su discusión, pregunta por pregunta. La sección 6 cierra con las conclusiones del avance y lo que queda pendiente para la etapa de visualización.

## 2. Necesidad y preguntas de negocio

La necesidad que orienta el proyecto es contar con una caracterización descriptiva de las tres especies de *Iris* a partir de mediciones simples de sépalo y pétalo, de modo que las tablas resultantes permitan comparar las especies entre sí y servir de base para la identificación de ejemplares y para la presentación gráfica de la etapa siguiente. Las mediciones que trae el dataset son el largo y el ancho del sépalo y del pétalo, en centímetros, junto con la etiqueta de especie de cada flor.

Las cuatro preguntas de negocio que guían esta etapa se resumen en la Tabla 1, junto con las variables que cada una requiere y el resultado que se espera obtener. Las tres primeras trabajan con las medidas originales; la cuarta se apoya en variables calculadas durante el enriquecimiento.

**Tabla 1**

*Preguntas de negocio, variables necesarias y resultado esperado*

| N.º | Pregunta de negocio | Variables necesarias | Resultado esperado |
|---|---|---|---|
| P1 | ¿Cómo se caracteriza morfológicamente cada especie? | Especie y las cuatro medidas (largo y ancho de sépalo y pétalo) | Tabla de estadísticos por especie y medida |
| P2 | ¿Las especies se diferencian más por el sépalo o por el pétalo? | Las cuatro medidas, agrupadas por especie | Comparación de la variación interna y de la distancia entre especies |
| P3 | ¿Qué relación existe entre las medidas del sépalo y las del pétalo? | Las cuatro medidas, con correlaciones globales y por especie | Tabla de correlaciones de Pearson por par de variables |
| P4 | ¿Cómo se distribuyen los ejemplares según el tamaño de la flor? | Especie, área del pétalo y categoría de tamaño (calculadas) | Conteos y porcentajes por categoría y cruce con la especie |

El dataset es de dominio público y no contiene datos personales, así que no hay restricción para publicarlo completo en el repositorio junto con los resultados. Si alguna pregunta no pudiera responderse con la información disponible, la limitación se declara en la sección correspondiente en lugar de forzar una respuesta.

## 3. Metodología

### 3.1 Transformaciones aplicadas

El cuaderno carga el dataset con la clase construida en la entrega anterior y conserva de inmediato una copia sin modificar, que sirve al final para comparar qué cambió y qué no. Sobre una copia de trabajo se aplican las operaciones que el estado de los datos pedía, en el orden de la Tabla 2. Ninguna operación eliminó registros: las 150 flores originales siguen presentes en el dataset preparado.

**Tabla 2**

*Transformaciones aplicadas al dataset y registros afectados*

| Operación | Decisión | Registros afectados |
|---|---|---|
| Verificación de tipos | Las seis columnas llegan con el tipo esperado; no se convierte nada | Ninguno (control sin hallazgos) |
| Renombrar columnas | Las seis columnas pasan a español con la unidad en el nombre | 150 filas (todas) |
| Normalizar la especie | Se retira el prefijo *Iris-* y se pasa a minúscula | 150 valores |
| Valores faltantes | El control no detectó nulos; no se aplica tratamiento | Ninguno |
| Duplicados | Dos grupos de medidas idénticas (cinco flores); se conservan | 5 filas revisadas |
| Valores atípicos | Cuatro anchos de sépalo fuera de 1,5 × RIC; se conservan | 4 valores revisados |
| Selección de columnas | Se descarta el identificador numérico por no aportar al análisis | 1 columna |

La verificación de tipos merece una aclaración: en lugar de convertir tipos por precaución, el cuaderno compara el tipo de cada columna contra el que documenta el dataset y solo actúa si hay desajuste. No lo hubo, y el control quedó registrado como parte de la evidencia.

Lo mismo aplica a los valores faltantes: columna a columna no aparece ningún nulo, así que no fue necesario decidir entre eliminación o imputación.

**3.2 Reglas de calidad y decisiones sobre los hallazgos**

Los dos controles con hallazgos fueron el de duplicados y el de atípicos, y en ambos casos la decisión fue conservar los datos con el hallazgo documentado. En el control de duplicados aparecieron dos grupos con las cuatro medidas exactamente iguales: tres flores *setosa* (identificadores 10, 35 y 38) y dos *virginica* (102 y 143). Como cada fila conserva su propio identificador, se trata de ejemplares distintos cuyas medidas coinciden a la precisión registrada (un décimo de centímetro), algo razonable en datos biológicos. Eliminar tres de cada cien flores de una especie alteraría las frecuencias sin corregir ningún error de captura.

Para los atípicos se aplicó la regla de 1,5 veces el rango intercuartílico (Tukey, 1977), solo como control de detección y no como criterio de borrado. Solo el ancho del sépalo presentó valores fuera del rango: tres flores con sépalos de 2,0 cm y una con 4,4 cm. Revisados uno a uno, son valores medibles y coherentes con la variabilidad natural de la especie, no errores de digitación, por lo que permanecen en el dataset. La regla de Tukey es una alerta para revisar, no una sentencia para eliminar.

### 3.3 Enriquecimiento de la información

Las variables nuevas se calculan a partir de las medidas existentes, sin combinar tablas externas: el dataset ya contiene lo que las preguntas necesitan, y una fuente adicional no aportaría a una caracterización morfológica. La Tabla 3 resume las cuatro variables incorporadas, su regla de construcción y las preguntas que apoyan. Las dos áreas y la razón entre largo y ancho ya se habían ensayado con fines ilustrativos en la entrega anterior; aquí se incorporan formalmente al análisis y se les suma la categoría de tamaño.

**Tabla 3**

*Variables incorporadas en el enriquecimiento*

| Variable | Fórmula o regla | Significado | Preguntas que apoya |
|---|---|---|---|
| area_sepalo_cm2 | largo del sépalo × ancho del sépalo | Superficie aproximada del sépalo, en cm² | P1 y P2 (tamaño global de la flor) |
| area_petalo_cm2 | largo del pétalo × ancho del pétalo | Superficie aproximada del pétalo, en cm² | P2 y P4 (tamaño del pétalo) |
| ratio_petalo | largo del pétalo ÷ ancho del pétalo | Proporción entre las dimensiones del pétalo | P2 (forma del pétalo) |
| tamano_flor | Terciles de area_petalo_cm2 | Categoría de tamaño: Pequeña, Media o Grande | P4 (distribución por categorías) |

La categoría de tamaño usa cortes por terciles del área del pétalo, de modo que cada categoría reúne cerca de un tercio de las flores: Pequeña por debajo de 2,52 cm², Media entre 2,52 y 7,71 cm², y Grande por encima de 7,71 cm². Elegí terciles porque garantizan categorías comparables entre sí, lo que facilita la lectura de la distribución de la P4; una alternativa con cortes fijos habría dependido de valores escogidos a mano.

### 3.4 Procedimiento para responder las preguntas

Cada pregunta se respondió con las agrupaciones y cálculos que su naturaleza pide, todas con operaciones estándar de pandas (Equipo de desarrollo de pandas, 2026): estadísticos por grupo con `groupby` para la P1 y la P2, coeficientes de correlación de Pearson con `corr` para la

P3, y tablas de frecuencia con `value_counts` y `crosstab` para la P4. La P3 se calculó dos veces por par de variables, primero sobre las 150 flores y luego dentro de cada especie, porque el comportamiento global y el interno pueden diferir; la sección 5 muestra que en este caso la diferencia es sustancial.

Al final de la ejecución el cuaderno exporta automáticamente el dataset preparado en `datos/dataset_preparado.csv`, las cinco tablas de resultados en `resultados/` y el resumen descriptivo del DataFrame final en `resultados/resumen_dataset_ae3.txt`, generado con la clase de resumen de la entrega anterior. Todos los archivos se regeneran en cada ejecución con rutas relativas, y una celda de verificación comprueba que los totales y porcentajes cuadran y que los archivos exportados coinciden con lo que hay en memoria: siete comprobaciones, todas superadas en la ejecución entregada.

Todo el desarrollo de la etapa queda en el repositorio público del proyecto: https://github.com/jesusjoelgonca/proyecto-integrado-iii-analitica-de-datos. Allí está la carpeta `AE3/` con el cuaderno ejecutado, las clases en `src/`, el dataset preparado, las tablas de resultados, el resumen y este documento, junto con la entrega anterior conservada en su lugar. La integración continua del repositorio ejecuta el cuaderno de principio a fin en Linux y Windows con cada cambio, de modo que los resultados se pueden reproducir en cualquiera de los dos entornos.

## 4. Diccionario de datos

La Tabla 4 actualiza el diccionario con las nueve columnas del dataset preparado: las cinco que hereda del dataset original (cuatro renombradas y la especie normalizada) y las cuatro incorporadas en el enriquecimiento.

**Tabla 4**

*Diccionario de datos del dataset preparado*

| Variable | Tipo | Unidad | Significado | Origen |
|---|---|---|---|---|
| largo_sepalo_cm | Decimal | cm | Largo del sépalo de la flor | Original (renombrada) |
| ancho_sepalo_cm | Decimal | cm | Ancho del sépalo de la flor | Original (renombrada) |
| largo_petalo_cm | Decimal | cm | Largo del pétalo de la flor | Original (renombrada) |
| ancho_petalo_cm | Decimal | cm | Ancho del pétalo de la flor | Original (renombrada) |
| especie | Texto | – | Especie de la flor: setosa, versicolor o virginica | Original (normalizada) |
| area_sepalo_cm2 | Decimal | cm² | Superficie aproximada del sépalo | Calculada |
| area_petalo_cm2 | Decimal | cm² | Superficie aproximada del pétalo | Calculada |
| ratio_petalo | Decimal | adimensional | Largo del pétalo dividido por su ancho | Calculada |
| tamano_flor | Categoría | – | Categoría de tamaño según terciles del área del pétalo | Calculada |

El identificador numérico del dataset original no aparece en el diccionario porque se descartó en la transformación; quedó documentado igualmente en la metodología, que es donde se registra la decisión y su justificación.

## 5. Resultados y discusión

Esta sección presenta las tablas que responden cada pregunta, con sus interpretaciones y limitaciones. Todas las cifras provienen de la ejecución del cuaderno y coinciden con los archivos CSV exportados en `resultados/`.

### 5.1 Perfil morfológico por especie (P1)

La Tabla 5 resume la media de cada medida por especie; el cuaderno acompaña el resultado con la mediana y la desviación de cada una.

**Tabla 5**

*Media de cada medida por especie, en centímetros*

| Especie | Largo sépalo | Ancho sépalo | Largo pétalo | Ancho pétalo | Área pétalo (cm²) |
|---|---|---|---|---|---|
| Setosa | 5,01 | 3,42 | 1,46 | 0,24 | 0,36 |
| Versicolor | 5,94 | 2,77 | 4,26 | 1,33 | 5,72 |
| Virginica | 6,59 | 2,97 | 5,55 | 2,03 | 11,30 |

Las tres especies forman un gradiente claro de tamaño. Setosa es la más pequeña en pétalo (su área media es de 0,36 cm², más de treinta veces menor que la de virginica), pero tiene el sépalo más ancho de las tres. Virginica encabeza las cuatro medidas menos el ancho del sépalo, y versicolor queda al centro en todo. En cada especie la media y la mediana de las medidas casi coinciden, lo que indica distribuciones sin asimetrías fuertes. La limitación de esta respuesta es la habitual en datos de muestra: las cifras describen las cincuenta flores por especie de este dataset histórico y no constituyen parámetros de las especies en general.

### 5.2 Variación dentro de las especies y distancia entre ellas (P2)

Para comparar sépalo contra pétalo se usaron dos ángulos: el coeficiente de variación dentro de cada especie y la distancia entre las medias de las tres especies, medida como diferencia relativa sobre la media global de cada medida (Tabla 6).

**Tabla 6**

*Coeficiente de variación por especie y distancia entre medias, por medida*

| Medida | CV setosa | CV versicolor | CV virginica | Rango entre medias (cm) | Diferencia relativa |
|---|---|---|---|---|---|
| Largo sépalo | 7,0 % | 8,7 % | 9,7 % | 1,58 | 27,1 % |
| Ancho sépalo | 11,1 % | 11,3 % | 10,8 % | 0,65 | 21,2 % |
| Largo pétalo | 11,9 % | 11,0 % | 9,9 % | 4,09 | 108,8 % |
| Ancho pétalo | 43,9 % | 14,9 % | 13,6 % | 1,78 | 148,7 % |

La respuesta salió clara: por el pétalo. La diferencia entre especies alcanza el 108,8 % del valor medio en el largo del pétalo y el 148,7 % en el ancho, mientras que en las dos medidas del sépalo apenas llega al 27,1 % y el 21,2 %. Dicho de otro modo, dos flores de especies distintas casi siempre se distinguen mirando el pétalo, mientras que los sépalos se cruzan entre especies con mucha más frecuencia. El coeficiente de variación alto del ancho del pétalo en setosa (43,9 %) refleja lo diminuto de su promedio (0,24 cm) más que una dispersión real. La limitación de esta comparación es que queda en lo descriptivo: sirve para orientar qué variables mirar, pero no equivale a probar un modelo de identificación, que sería el paso siguiente si la necesidad lo exigiera.

### 5.3 Relación entre sépalo y pétalo (P3)

La Tabla 7 muestra las correlaciones de Pearson de los cuatro pares sépalo–pétalo, calculadas sobre todo el dataset y dentro de cada especie.

**Tabla 7**

*Correlación de Pearson de cada par sépalo–pétalo, global y por especie*

| Par de variables | Global | Setosa | Versicolor | Virginica |
|---|---|---|---|---|
| Largo sépalo × largo pétalo | 0,87 | 0,26 | 0,75 | 0,86 |
| Largo sépalo × ancho pétalo | 0,82 | 0,28 | 0,55 | 0,28 |
| Ancho sépalo × largo pétalo | −0,42 | 0,18 | 0,56 | 0,40 |
| Ancho sépalo × ancho pétalo | −0,36 | 0,28 | 0,66 | 0,54 |

Lo que más me llamó la atención está en el ancho del sépalo. Globalmente su correlación con el pétalo es negativa (−0,42 con el largo y −0,36 con el ancho), pero dentro de cada especie la relación vuelve a ser positiva, hasta 0,66 en versicolor. El signo negativo global lo produce la composición de la muestra: setosa, la especie de sépalo más ancho, tiene los pétalos más pequeños, y ese contraste entre especies arrastra la correlación hacia abajo cuando se calcula sobre las 150 flores juntas. Es una ilustración concreta de que una relación calculada sobre el total puede invertirse al mirar por grupo, y justifica que el procedimiento calculara las dos versiones. La limitación es doble: correlación no implica causalidad, y con cincuenta flores por especie los coeficientes internos llevan bastante incertidumbre.

### 5.4 Distribución por categorías de tamaño (P4)

Con los cortes por terciles definidos en la metodología, cada categoría reúne exactamente cincuenta flores, un tercio del total (Tabla 8). El cruce con la especie fue lo más claro que dejó la etapa.

**Tabla 8**

*Distribución de especies por categoría de tamaño de flor*

| Especie | Pequeña | Media | Grande |
|---|---|---|---|
| Setosa | 50 flores (100 %) | 0 flores (0 %) | 0 flores (0 %) |
| Versicolor | 0 flores (0 %) | 47 flores (94 %) | 3 flores (6 %) |
| Virginica | 0 flores (0 %) | 3 flores (6 %) | 47 flores (94 %) |

La categoría Pequeña es completamente setosa, y las otras dos especies se reparten Media y Grande casi sin mezclarse: solo seis flores quedan en la categoría vecina a la de su especie. El área del pétalo, una variable calculada, resume en una sola cantidad la separación que la P2 dejó ver medida por medida, y deja las frecuencias listas para el gráfico de la etapa siguiente. La limitación que corresponde registrar es que los cortes de 2,52 y 7,71 cm² dependen de esta muestra: con otros datos los terciles se moverían y alguna flor cambiaría de categoría, así que la categoría es descriptiva y no una regla de identificación validada.

## 6. Conclusiones del avance

La etapa deja el dataset listo para responder la necesidad planteada. Las transformaciones corrigieron lo que los datos pedían (nombres, formato de la especie, descarte del identificador) sin eliminar ni un registro, y los controles de calidad quedaron documentados con su decisión: cinco flores con medidas repetidas y cuatro anchos de sépalo atípicos se conservaron porque son valores plausibles y no errores. El enriquecimiento añadió cuatro variables que convierten medidas aisladas en información comparable: las áreas resumen el tamaño, la razón del pétalo su forma, y la categoría de tamaño agrupa los ejemplares en tres grupos equilibrados.

Respecto a la necesidad, el análisis ya permite conocer lo esencial: las especies forman un gradiente de tamaño, el pétalo las separa mucho mejor que el sépalo, la relación entre sépalo y pétalo es fuerte pero depende del alcance del cálculo, y el tamaño de la flor clasificado por terciles reproduce la separación de las especies casi sin equivocaciones. Las tablas de resultados quedaron exportadas y verificadas, de modo que la etapa de visualización puede apoyarse directamente en ellas.

Quedan abiertos tres frentes para la etapa que sigue. El más inmediato es la representación gráfica de estas tablas, que ya quedó lista para graficarse. También falta validar la categoría de tamaño como regla de identificación: el cruce de la P4 sugiere que un corte simple por el área del pétalo acierta la especie casi siempre, pero confirmarlo exigiría técnicas de clasificación ajenas al alcance descriptivo de esta entrega. Y si el proyecto lo requiriera, el paso natural sería profundizar en las relaciones entre medidas dentro de cada especie, que mostraron comportamientos distintos entre sí, con pruebas estadísticas de significancia.

## 7. Referencias

Anderson, E. (1935). The irises of the Gaspé Peninsula. *Bulletin of the American Iris Society, 59*, 2–5.

Equipo de desarrollo de pandas. (2026). *User guide de pandas* (versión 2.3) [Documentación en línea]. https://pandas.pydata.org/docs/

Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics, 7*(2), 179–188. https://doi.org/10.1111/j.1469-1809.1936.tb02137.x

Hugging Face. (2026). *Documentación de la librería datasets* [Documentación en línea]. https://huggingface.co/docs/datasets

IU Digital. (2026). *Proyecto integrador III, analítica de datos: recursos de aprendizaje* [Aula virtual]. Universidad Internacional.

McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt & J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

scikit-learn. (2024). *Iris* [Conjunto de datos]. Hugging Face. https://huggingface.co/datasets/scikit-learn/iris

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

Wickham, H. (2014). Tidy data. *Journal of Statistical Software, 59*(10), 1–23. https://doi.org/10.18637/jss.v059.i10

## Apéndice A. Contenido del resumen descriptivo

El cuaderno genera en cada ejecución el archivo `resultados/resumen_dataset_ae3.txt` con la descripción del DataFrame final. Su contenido corresponde a la ejecución entregada.

```
================================================================================
                                RESUMEN DEL DATASET
================================================================================
Nombre    : Iris transformado y enriquecido (AE3)
Origen    : Hugging Face · scikit-learn/iris · split=train

1. DIMENSIONES
Filas      : 150
Columnas   : 9
Duplicados : 3 filas (2.00 %)

2. COLUMNAS Y TIPOS
1  largo_sepalo_cm  float64    150      0      0.0      35
2  ancho_sepalo_cm  float64    150      0      0.0      23
3  largo_petalo_cm  float64    150      0      0.0      43
4  ancho_petalo_cm  float64    150      0      0.0      22
5  especie          object     150      0      0.0       3
6  area_sepalo_cm2  float64    150      0      0.0     108
7  area_petalo_cm2  float64    150      0      0.0      97
8  ratio_petalo     float64    150      0      0.0      83
9  tamano_flor      category   150      0      0.0       3

3. VALORES NULOS
Sin valores nulos: todas las columnas estan completas.

5. VARIABLES CATEGORICAS
especie (3 categorias): setosa (50), versicolor (50), virginica (50)
tamano_flor (3 categorias): Pequeña (50), Media (50), Grande (50)
================================================================================
```